基于混合专家机制 (MoE) 的时序预测模型融合与跨 Seed 鲁棒性实证研究

——以 MLF 与 DUET 架构融合为例

1. 摘要与研究动机

长序列时间序列预测（Long-term Forecasting）在复杂分布下面临着严重的特征提取瓶颈。虽然 MLF（主干网络）等经典 baseline 模型表现优异，但在跨通道特征交互上仍有提升空间。本研究旨在探索：能否通过引入 DUET 架构中的多专家路由（MoE）模块生成通道掩码（Channel Mask），实现跨通道信息的有效注入，从而在 MLF 的基础上实现“1+1>2”的性能突破。

2. 融合架构设计与演进策略

本研究设计了从“静态参数注入”到“动态路由自适应”的两阶段演进方案：

2.1 阶段一：静态残差融合

在打通 MLF 与 DUET 的推理流程后，首创了残差式通道掩码融合机制 。具体跨通道信息注入公式为： $u \leftarrow (1-\alpha)u + \alpha \cdot (u \mathbin{@} mask)$ 在此阶段，融合强度超参数 α 决定了跨通道信息注入的比例 。

2.2 阶段二：Staged-Freeze 动态联合训练

为突破静态融合的性能上限，设计了分段冻结训练策略 。具体操作为：冻结 MLF 主干网络参数 ，仅针对 DUET 侧生成 mask 的模块（即 clustering/gate/MoE 路由参数）进行反向传播训练，使得 mask 由固定规则变为数据自适应 。

3. 实验设置与严谨性控制

为确保研究结论的可靠性，本实验实施了极其严格的变量控制机制：

- **数据集与任务：** 采用经典的 ETTh1 数据集（ETTh1_fixed.csv）执行长序列预测任务 。
- **超参数对齐：** 全局统一定义预测长度 pred_len = 96 与 batch_size = 8 。优化与对比主要以 MSE 为核心指标 。
- **底线测试（Baseline Test）：** 针对同一 Checkpoint 重复评估，确认评估指标完全一致，严格排除了测试框架自身的随机抖动。

4. 核心发现与深度剖析

4.1 发现一：静态融合具备微弱但稳定的增益

为了寻找最佳融合强度，本研究对 α 进行了细致的扫描（**α ∈ {0.0, 0.002, 0.005, 0.01, 0.02, 0.03, 0.05, 0.06}**）。实验发现，MSE 随 α 增大呈现先下降后回升的趋势 ：

- 当 α = 0.05 时，MSE 达到当前扫描最优的 0.4090594 。
- 当 α = 0.06 时，MSE 回升至 0.4090698，确认最优点已过 。

在固定 α = 0.05 的控制变量条件下 ，对 Seed=1986 和 Seed=2020 进行稳定性验证 ，两组实验均呈现方向一致的指标改善：

- Seed 1986：Baseline（0.4093648）；Fusion（0.4090594）
- Seed 2020：Baseline（0.4095406）；Fusion（0.4092172）两组 Seed 平均 ΔMSE 约为 -0.0003144 。

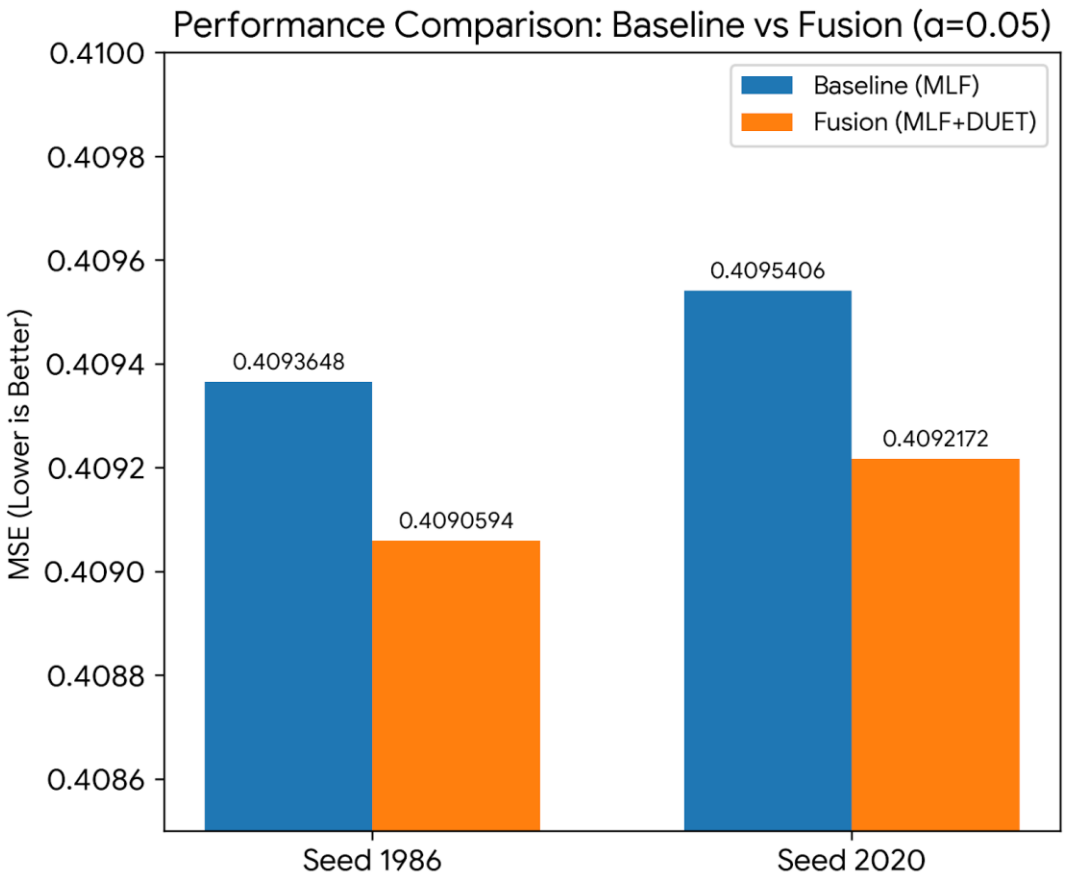

结论： 静态通道掩码注入确实能够为 MLF 带来信息增益，提升方向一致，但整体偏向“微增益” 。

4.2 发现二：动态路由架构面临极端的初始化敏感性（跨 Seed 失效）

在使用小学习率进行短周期试训后 ，实验呈现出高度的随机种子敏感性。虽然在特定 Seed 下融合模型相对 baseline 存在极小幅度改善，但在新增的验证 Seed 下，动态融合模型与 baseline 彻底持平，个别情形甚至出现性能倒退。

4.3 深度失效归因（Failure Analysis）

针对动态阶段的“跨 Seed 震荡”，本研究归纳出以下深层架构瓶颈：

1. **MoE 门控路由崩塌（Gate Collapse）：** 由于时间序列存在强烈的周期性与趋势惯性，缺乏明确负载均衡损失约束的门控网络极易陷入次优解，导致对专家的分配极度不均，丧失了多专家架构的容量优势。
2. **批次方差过大：** 实验中设置的 batch_size = 8 在常规网络中适用 ，但在包含门控选择概率的混合专家网络中，过小的 Batch 导致路由概率的梯度方差极大，使得网络在探索期极其依赖完美的初始化 Seed。

5. 结论与未来展望

本实证研究表明，在具有极高基准性能的长序列时序预测任务中，基于多专家路由（MoE）的模型融合难以通过简单的模块叠加实现稳定飞跃。从静态注入的微小增益到动态路由的跨 Seed 震荡，凸显了深度时序模型对结构精细度及超参数调度的极高门槛。未来的探索应聚焦于引入专门针对连续分布数据的时序路由损失函数，或对门控策略进行更严格的硬性阈值约束。